



CNPEM

MINISTÉRIO DA
CIÊNCIA, TECNOLOGIA
E INOVAÇÃO



Implementação de protocolo de processamento de imagens em ensaios fenotípicos de viabilidade celular

Relatório do projeto de pesquisa apresentado à Fundação de Amparo à Pesquisa do
Estado de São Paulo (FAPESP) para solicitação de bolsa de Iniciação Científica

Bolsista: Kayllany Lara da Silva Oliveira

Orientador: Dr. João Victor da Silva Guerra

Coorientador: Dr. José Geraldo de Carvalho Pereira

Coorientadora: Dra. Ana Amélia Sanchez Iacia

Laboratório Nacional de Biociências - LNBio

Centro Nacional de Pesquisa em Energia e Materiais - CNPEM

Campinas - SP

Brasil

2025

Resumo

A triagem de alto conteúdo tem se tornado uma metodologia fundamental na descoberta de fármacos e investigação de mecanismos biológicos. No entanto, o processamento e análise do grande volume de imagens geradas representam um desafio significativo para pesquisadores. Este projeto propõe o desenvolvimento de um protocolo automatizado de processamento de imagens para ensaios fenotípicos de viabilidade celular, utilizando ferramentas de código aberto e integrável à clusters de computação de alto desempenho. O protocolo será desenvolvido na linguagem de programação Python, usando bibliotecas como CellProfiler, scipy, scikit-image e CellPose, para processamento de imagens de fluorescência de células Vero CCL81 e HuH7.0 marcadas com Hoechst 33342. As etapas incluem pré-processamento de imagens, segmentação de núcleos, extração de características morfológicas e integração de dados. Os resultados serão comparados com o software comercial Acapella/Columbus, utilizado como método de referência. A validação será realizada em um conjunto de dados de ensaio fenotípico para descoberta de fármacos, envolvendo aproximadamente 7.700 compostos e diferentes vírus. O protocolo será disponibilizado como ferramenta de código aberto, promovendo colaboração científica e facilitando a análise de imagens de viabilidade celular em diferentes contextos de pesquisa.

Palavras-chave: Descoberta de fármacos, triagem de alto conteúdo, viabilidade celular, análise de imagens, segmentação de imagens, computação de alto desempenho

Sumário

1	Introdução	3
2	Objetivos	9
2.1	Objetivos específicos	9
3	Metodologia e implementação	10
3.1	Imagens biológicas	10
3.2	Desenvolvimento do protocolo de processamento de imagens em ensaios de viabilidade celular	11
3.2.1	Carregamento dos ensaios	11
3.2.2	Segmentação dos núcleos e extração de características morfológicas	11
3.2.3	Normalização dos dados	12
3.2.4	Controle de qualidade das placas	12
3.2.5	Visualização dos dados	13
3.2.6	Integração dos dados e seleção dos compostos candidatos	13
4	Resultados e discussões	15
4.1	Arquivo de configuração	16
4.2	Leitura dos dados	18
4.3	Segmentação das imagens	19
5	Resultados preliminares	19
6	Considerações finais	24
	Referências	25

1 Introdução

A microscopia óptica, especialmente a técnica de microscopia por fluorescência [1, 2], tem sido fundamental para avanços nas ciências da vida [3, 4]. A microscopia por fluorescência (Figura 1) permite a visualização detalhada de estruturas celulares e interações moleculares, sendo amplamente utilizada para investigar processos intracelulares, descobrir novos fármacos e elucidar mecanismos de diversas patologias. A excitação do fluoróforo gera emissão de luz em comprimentos de ondas específicos, permitindo a marcação simultânea de múltiplas estruturas e biomoléculas. Esse princípio possibilita a aquisição de imagens em múltiplos canais, cada um correspondendo a um intervalo espectral distinto. A análise dessas imagens fornece informações qualitativas e quantitativas, tornando a microscopia por fluorescência uma ferramenta essencial em áreas como biologia celular, virologia, farmacologia, imunologia e oncologia [5, 6].




Figura 1: Microscopia por fluorescência. (A) Representação esquemática de um microscópio de fluorescência. (B) Espectros de emissão de diferentes fluoróforos. (C) Imagem multicanal de células marcadas com diferentes fluoróforos, usando os canais vermelho, verde e azul.

Entre as aplicações mais relevantes dessa técnica está a descoberta de fármacos, que tem se beneficiado do desenvolvimento de plataformas automatizadas para captura e análise de imagens em larga escala. Nesse contexto, a triagem de alto conteúdo (HCS; do inglês, *High-Content Screening*), geralmente executadas em microplacas de 96 ou 384 poços, combina microscopia de fluorescência automatizada com análise quantitativa de imagens, permitindo a obtenção de dados multiparamétricos. Essa abordagem permite a caracterização detalhada de fenótipos celulares em resposta a diferentes tratamentos,

viabilizando a marcação seletiva de componentes subcelulares com fluoróforos específicos e a aquisição sistemática de imagens sob diversas condições experimentais. Isso, por sua vez, permite classificar e interpretar os efeitos de potenciais fármacos [3, 7].

Experimentos de HCS, comumente denominados *screenings*, requerem três etapas independentes: preparação da amostra, aquisição de imagens, e manuseio e processamento de imagens (Figura 2). Cada etapa apresenta desafios técnicos significativos que precisam ser considerados. Para garantir a reprodutibilidade e escalabilidade dos ensaios de HCS, é fundamental desenvolver protocolos experimentais padronizados que minimizem a variabilidade entre amostras e placas. Sistemas de imagem são frequentemente acoplados a dispositivos automatizados de transferência de líquidos, o que aumenta a precisão e reduz as variações experimentais. A escolha do sistema de microscopia também acelera a produção de dados. A tecnologia de campo amplo (do inglês, *widefield*) dos microscópios HCS é mais rápida do que os microscópios confocais tradicionais, oferecendo um alto sinal de fluorescência e gerando uma grande quantidade de dados, mesmo em altas magnificações (e.g, 20x, 40x e 60x) [3].




Figura 2: Representação esquemática das etapas triagem automatizada de alto conteúdo. A preparação da amostra envolve a marcação de células com fluoróforos específicos e a distribuição em placas de ensaio. A aquisição de imagens é realizada em microscópios automatizados de fluorescência, capturando imagens em múltiplos canais. O manuseio e processamento de imagens envolve a segmentação de células, extração de características e análise de dados.

Além da aquisição de imagens, um dos desafios mais críticos do HCS está no manuseio e processamento computacional do grande volume de imagens geradas. A análise manual de imagens, predominante nos primeiros dias dos ensaios de HCS, ainda é usada em estudos de baixa e média produtividade, mas é inviável para experimentos de HCS devido ao tempo e subjetividade envolvidos. Em campanhas de triagem, geralmente centenas ou até milhares de compostos são testados em dezenas de placas de ensaios de 384 poços.

Nesse contexto, a análise (semi-)automatizada de imagens é essencial para a interpretação dos dados dessas dezenas de placas, permitindo a extração de informações quantitativas e a identificação de padrões complexos em grandes conjuntos de imagens [3].

Os principais passos para a análise de bioimagens (Figura 3) envolvem o pré-processamento para melhorar a qualidade da imagem, a segmentação para identificar objetos de interesse, a extração de características para converter dados brutos em informações relevantes e a análise estatística para interpretar os resultados. Esses processos, quando combinados, possibilitam a obtenção de informações biológicas a partir das imagens, garantindo maior precisão e reprodutibilidade na quantificação de fenômenos celulares e moleculares [3, 8].



Fonte: Adaptado de [3].

Figura 3: Representação esquemática de um protocolo geral de processamento de imagens biológicas. O fluxo de trabalho é composto por várias etapas, incluindo pré-processamento, segmentação de objetos e extração de características até a mineração de dados. Existem diversos algoritmos disponíveis para cada etapa, dependendo do tipo de imagem e do objeto de interesse, incluindo métodos de aprendizado de máquina e aprendizado profundo.

Após a aquisição automatizada de imagens, é necessário corrigir as imagens para ruídos (e.g, ruído de fundo ou artefatos experimentais) e iluminação desigual, geralmente aplicando diferentes filtros para suavizar o ruído [9]. O próximo passo é segmentar as regiões de interesse, que podem ser células, núcleos ou estruturas subcelulares. A segmentação é crucial, pois define as regiões de interesse (ROIs; do inglês, *regions of interest*) que serão analisadas. A segmentação pode ser desafiadora, especialmente quando os objetos estão próximos ou quando a intensidade dos objetos é semelhante ao fundo. Diversos algoritmos foram desenvolvidos para enfrentar esses desafios, incluindo métodos baseados em limiarização, morfologia matemática, transformadas de imagem e redes neurais convolucionais [10–14]. Após a segmentação, podem ser adquiridas medições quantitativas representativas das células ou objetos subcelulares. Uma variedade de descritores numéricos

comumente usados no campo da visão computacional foi desenvolvida, incluindo resumos da distribuição de intensidade, forma, tamanho, textura, distribuição radial e granularidade das ROIs segmentadas [3]. Nem todas as características extraídas são igualmente informativas para uma determinada questão biológica, e muitas delas podem ser altamente redundantes. Após a extração e seleção de características, três abordagens gerais de análise de dados podem ser realizadas usando as características morfométricas quantitativas: comparações estatísticas, aprendizado supervisionado e aprendizado não supervisionado. O HCS pode coletar centenas de características para cada ROI, mas os pesquisadores frequentemente necessitam apenas de uma ou algumas características derivadas de imagens e de métricas estatísticas calculadas para análise subsequente [3].

O Laboratório Nacional de Biociências (LNBio) do Centro Nacional de Pesquisa em Energia e Materiais (CNPEM) dispõe de dois sistemas de microscopia automatizada *Operetta CLS High-Content Analysis System* (Perkin Elmer), amplamente utilizados em ensaios de triagem para descoberta de fármacos. Esses sistemas, alocados no Laboratório de Bioensaios (LBE), permitem a análise de milhares de compostos em ensaios de fluorescência de viabilidade celular, caracterizados pela contagem de células (i.e, núcleos) após tratamento com compostos, reagentes e/ou patógenos. A partir do segundo semestre de 2025, o LNBio/CNPEM também abrirá esses sistemas para propostas de pesquisa de instituições acadêmicas externas, ampliando seu uso em estudos de descoberta de fármacos e investigação de mecanismos biológicos. Levantamentos internos indicam que ensaios de fluorescência de viabilidade celular estão entre os experimentos mais frequentemente realizados nesses sistemas.

O armazenamento e processamento dos grandes volumes de dados gerados por experimentos de HCS requerem infraestruturas computacionais robustas, capazes de lidar com a complexidade e a escala dessas análises. No LNBio/CNPEM, as imagens coletadas nesses sistemas são armazenadas em um repositório de imagens denominado OMERO [15–17], hospedado no cluster de computação de alto desempenho (HPCC; do inglês, *High Performance Computing Cluster*) Marvin. Esse cluster também oferece uma solução ideal para o processamento de dados, permitindo o gerenciamento eficiente de tarefas simul-

tâneas e a execução de algoritmos de alto custo computacional. Com sua capacidade de processamento paralelo e escalabilidade, o HPCC Marvin viabiliza a implementação de ferramentas avançadas, como modelos de aprendizado de máquina, garantindo maior rapidez, eficiência e reprodutibilidade na análise de dados [18].

No entanto, os protocolos internos de processamento de imagens são baseados em softwares comerciais, como o Acapella/Columbus (PerkinElmer, versão 2.4.0.104236, 2013). Embora amplamente utilizados, esses softwares apresentam limitações significativas, como alto custo, execução serial de tarefas, falta de flexibilidade para diferentes condições experimentais e ausência de paralelização de funções. Assim, há uma necessidade urgente de atualizar e otimizar os protocolos de processamento, visando maior acurácia, eficiência computacional e reprodutibilidade dos resultados. A integração de novos protocolos ao HPCC do LNBio/CNPEN permitirá a execução paralela de tarefas e o uso de algoritmos avançados, como aprendizado profundo. Além disso, a disponibilização do protocolo como ferramenta de código aberto no GitHub, acompanhada de documentação detalhada, fomentará colaborações científicas e o aprimoramento contínuo, garantindo acessibilidade e ampla usabilidade.

Este projeto tem como objetivo desenvolver e implementar um protocolo automatizado de análise de imagens para ensaios fenotípicos de viabilidade celular, utilizando técnicas avançadas de processamento de imagens. Com o aumento da utilização de HCS na descoberta de fármacos e na investigação de mecanismos biológicos, a análise de grandes volumes de dados gerados por essas plataformas tornou-se um desafio significativo. Atualmente, a necessidade de ferramentas integradas a HPCCs para processar e interpretar essas imagens limita o uso e a flexibilidade das tecnologias de HCS, dificultando seu uso pleno por diferentes grupos de pesquisa. Ao integrar o protocolo ao HPCC Marvin do LNBio/CNPEN, este projeto visa melhorar a precisão, reprodutibilidade e escalabilidade dos ensaios, otimizando a segmentação e extração de parâmetros fenotípicos. O desenvolvimento e a disponibilização desse protocolo como ferramenta de código aberto, com documentação detalhada, promoverão a colaboração científica e a adoção em outras plataformas, acelerando a descoberta de fármacos e contribuindo para avanços nas áreas de

biologia celular, farmacologia, virologia e oncologia. Por fim, este projeto possibilitará que instalações de HCS se beneficiem de um protocolo de processamento de imagens de alto desempenho, sem a necessidade de investimentos em softwares comerciais.

2 Objetivos

Desenvolver um protocolo de processamento de imagens usando ferramentas livres (*open-source*) para ensaios de fluorescência de viabilidade celular em experimentos de HCS.

2.1 Objetivos específicos

- (1) Desenvolver pacote para processamento de imagens em ensaios fenotípicos de viabilidade celular em experimentos de HCS;
- (2) Comparar a segmentação de imagens com o método de referência em ensaios fenotípicos de viabilidade celular;
- (3) Validar e avaliar o protocolo em um conjunto de dados provenientes de um ensaio de viabilidade celular para descoberta de fármacos;
- (4) Documentar o protocolo de processamento de imagens para o usuário final.

3 Metodologia e implementação

O projeto foi desenvolvido pela Equipe de Dados Biológicos (EDB), com validação experimental realizada a partir de dados do Laboratório de Bioensaios (LBE) do LNBio, instalação aberta do CNPEM. O processamento das imagens biológicas da triagem automatizada foi realizado no cluster de computação de alto desempenho do LNBio, denominado de HPCC Marvin, composto por 2 nós de processamento com 128 núcleos, sendo que um deles possui 8 GPUs NVIDIA A100 (40GB).

3.1 Imagens biológicas

As imagens de fluorescência dos ensaios de viabilidade celular foram fornecidas pelo grupo de Virologia do LNBio/CNPEM, liderado pelo Dr. Rafael Elias Marques. As aquisições foram realizadas em placas de 384 poços, usando o sistema de microscopia *Operetta CLS High-Content Analysis System* (Perkin Elmer), com magnificação de 10x, capturando o campo central de cada poço.

Os experimentos envolveram a infecção das linhagens Vero CCL81 e HuH7.0 com os vírus Mayaro (MAYV), coronavírus da síndrome respiratória aguda grave 2 (SARS-CoV-2), Oropouche (OROV) e vírus da encefalite de St. Louis (SLEV). As células Huh-7 foram expostas a 7.784 compostos contra MAYV, OROV e SLEV, enquanto as células Vero CCL81 foram testadas com 3.212 compostos contra SARS-CoV-2. As células foram estocadas em 100% DMSO, além de controles não infectados (negativo) e infectados (positivo), ambos sem tratamento. Todas as amostras, incluindo controles, continham 0,4% de DMSO. A coloração celular foi realizada com o fluoróforo Hoechst 33342, um marcador de DNA, permitindo a segmentação dos núcleos celulares. A aquisição das imagens foi feita utilizando um filtro de excitação a 361 nm e emissão a 497 nm.

3.2 Desenvolvimento do protocolo de processamento de imagens em ensaios de viabilidade celular

O protocolo computacional de processamento de imagens em ensaios de viabilidade celular para descoberta de fármacos foi desenvolvido na linguagem Python. Para isso, foram usadas bibliotecas de código aberto para leitura, pré-processamento, segmentação e caracterização de imagens biológicas, incluindo BioIO [19], scikit-image [20], scipy.ndimage [21], Cellpose [13, 22, 23] e StarDist [12, 14, 24].

O protocolo foi estruturado em etapas principais:

- (1) carregamento das imagens dos ensaios com *lazy-loading*;
- (2) segmentação dos núcleos e extração de características morfológicas;
- (3) normalização dos dados;
- (4) controle de qualidade das placas;
- (5) visualização dos dados das placas;
- (6) integração dos dados de diferentes placas e seleção dos compostos candidatos.

3.2.1 Carregamento dos ensaios

A leitura das imagens foi implementada utilizando o conceito de *lazy-loading*, permitindo o carregamento sob demanda e reduzindo o consumo de memória total durante o processamento. Ainda, as imagens são organizadas por placas (384 poços), permitindo que as etapas posteriores operem de forma estruturada, poço a poço e placa a placa.

3.2.2 Segmentação dos núcleos e extração de características morfológicas

A segmentação das imagens foi realizada para isolar os núcleos das células Vero CCL81 e HuH7.0, marcados com Hoechst 33342. Para essa etapa, diferentes modelos avançados de reconhecimento de instância foram avaliados, incluindo:

- Cellpose 3.1.1.2 [13, 22]

- Cellpose 4.0.7 [23]
- StarDist 0.9.1 [12, 14, 24].

A seleção do modelo considerou acurácia de segmentação, custo computacional e escalabilidade. Os parâmetros de pré-processamento e segmentação permaneceram ajustáveis para acomodar variações experimentais entre linhagens e condições de infecção.

Após a segmentação, os núcleos celulares menores ou maiores que limiares definidos pelo usuário foram descartados para evitar contagens incorretas devido a artefatos ou núcleos sobrepostos. Em seguida, as características morfológicas dos núcleos com scikit-image [20], incluindo área, perímetro e excentricidade. Por fim, foi calculada a contagem total de células por poço, que servirá como métrica primária para avaliar a viabilidade celular nos ensaios.

3.2.3 Normalização dos dados

Para cada poço, a inibição do efeito citopático (inCPE) viral foi calculada, definida como:

$$\text{inCPE} = \frac{N_c - \mu_{c+}}{\mu_{c-} - \mu_{c+}} \quad (1)$$

onde N_c é a contagem de núcleos no poço avaliado, μ_{c+} é a média das contagens dos controles positivos (infectados, sem tratamento) e μ_{c-} é a média das contagens dos controles negativos (não infectados, sem tratamento) da mesma placa.

Essa normalização reduz o impacto de variações sistemáticas entre placas e facilita comparações diretas entre condições experimentais.

3.2.4 Controle de qualidade das placas

A qualidade das placas de ensaios de viabilidade celular foi avaliada pelo Z' -factor (Z') [25, 26], um índice estatístico que avalia a variabilidade dos dados entre os controles positivo (infectado e não tratado) e negativo (não infectado e não tratado). O Z' é calculado conforme a equação:

$$Z' = 1 - \frac{3\sigma_{c^+} + 3\sigma_{c^-}}{|\mu_{c^+} - \mu_{c^-}|}, \quad (2)$$

onde σ_{c^+} e σ_{c^-} representam os desvios padrão dos controles positivo e negativo, respectivamente, e μ_{c^+} e μ_{c^-} correspondem às suas médias.

Conforme estabelecido na literatura [26, 27], os valores de Z' são interpretados da seguinte forma:

- $Z' = 1, 0$: ensaio ideal, com separação perfeita entre os controles positivo e negativo;
- $0, 5 < Z' \leq 1, 0$: ensaio de alta qualidade, com boa separação entre os controles positivo e negativo;
- $0 < Z' \leq 0, 5$: ensaio aceitável, mas com alguma sobreposição entre os controles;
- $Z' = 0$: ensaio sem separação entre os controles positivo e negativo;
- $Z' < 0$: ensaio de baixa qualidade, com significativa sobreposição entre os controles.

Com base nessas interpretações, as placas com Z' menores que um limiar definido pelo usuário (por padrão, $Z' < 0, 5$) serão excluídas das análises subsequentes.

3.2.5 Visualização dos dados

A visualização dos resultados foi realizada com a biblioteca matplotlib [28] e Plotly [29]. As marcações dos núcleos segmentados serão sobrepostas às imagens originais, e os dados, como contagem de células e a inCPE serão apresentados em mapas de placa interativos, facilitando a interpretação dos resultados pelos usuários. Essas visualizações auxiliam na inspeção de artefatos, verificação da segmentação e identificação de padrões experimentais.

3.2.6 Integração dos dados e seleção dos compostos candidatos

Os dados provenientes das placas aprovadas no controle de qualidade foram integrados e processadas usando Pandas [30] e NumPy [31], permitindo filtragem, agregação e análise de grandes volumes de dados tabulares.

Após integração das placas, a seleção dos compostos candidatos (*hits*) baseou-se nos valores normalizados de inCPE, adotando-se um limiar definido pelo usuário (por padrão, $\text{inCPE} > 0,3$). Compostos com alto índice de inibição foram classificados como potenciais inibidores do efeito citopático viral.

4 Resultados e discussões

O pacote de código aberto **CellViability** (GPL 3.0) foi desenvolvido com o objetivo de implementar um protocolo robusto e reproduzível para o processamento de imagens provenientes de ensaios fenotípicos de viabilidade celular, aplicados à descoberta de fármacos. O código-fonte do pacote está disponível no repositório GitHub (<https://github.com/cnpem/CellViability>), acompanhado de documentação detalhada disponibilizada em <https://cnpem.github.io/CellViability/>.

A arquitetura do pacote foi organizada em três subpacotes principais (Figura 4): **protocols**, **screening** e **core**.




Figura 4: Diagrama de classes UML do protocolo **CellViability.** O diagrama ilustra a organização modular do pacote e os relacionamentos entre as principais classes envolvidas no processamento de imagens em ensaios fenotípicos de viabilidade celular.

O subpacote **protocols** contém a classe **CellViabilityProtocol**, responsável por estruturar o fluxo de processamento, incluindo leitura dos dados, segmentação de imagens, extração de características, integração dos dados e seleção dos *hits*. O subpacote **screening** reúne as classes que representam a hierarquia experimental de ensaios de des-

coberta de fármacos (i.e., **Screen**, **Plate**, **Well** e **Image**), permitindo organizar e acessar eficientemente os dados brutos de imagem.

O subpacote **core** contém o módulo **cli**, que fornece uma interface de linha de comando (CLI) para execução do pacote **CellViability** para facilitar a execução do protocolo pelos usuários finais (Figura 5). Essa CLI facilita o uso do protocolo pelos usuários finais, permitindo configurar e processar um ou mais ensaios de viabilidade celular a partir de um arquivo de configuração no formato JSON (**config.json**). Quando o arquivo contém múltiplos ensaios, cada um deve possuir seu próprio conjunto de parâmetros. Caso o usuário deseje executar apenas um ensaio específico, deve utilizar a opção **--index** seguida do índice correspondente (iniciando em zero).

```
1 $ CellViability --config config.json --basedir  
  ↪ /path/to/output/directory --instances --npz --verbose
```

Figura 5: Exemplo de comando para execução do protocolo CellViability via CLI. O comando executa o protocolo usando o arquivo de configuração **config.json**, salvando os resultados no diretório especificado por **/path/to/output/directory**. As opções adicionais incluem a geração de imagens de instâncias segmentadas (**--instances**), salvamento das instâncias segmentadas em formato NumPy (**--npz**) e ativação do modo verboso (**--verbose**).

4.1 Arquivo de configuração

O arquivo **config.json** (Figura 6) define os parâmetros do protocolo de processamento dos ensaios de viabilidade celular, possibilitando a adaptação do fluxo de trabalho para diferentes condições experimentais.

Os campos configuráveis incluem:

- **controls**: listas de poços correspondentes aos controles negativos (não infectados, sem tratamento) e positivos (infectados, sem tratamento) para cada ensaio;
- **datadir**: diretório raiz onde as imagens do ensaio estão armazenadas, seguindo a estrutura de diretórios especificada;
- **fields**: número de campos de imagem por poço (para os ensaios deste projeto, cada poço contém apenas um campo);

```

1  {
2    "MAYV": {
3      "controls": {
4        "negative": [
5          "A01", "B01", "C01", "D01", "E01", "F01", "G01", "H01",
6          "I01", "J01", "K01", "L01", "M01", "N01", "O01", "P01",
7          "A24", "B24", "C24", "D24", "E24", "F24", "G24", "H24",
8          "I24", "J24", "K24", "L24", "M24", "N24", "O24", "P24"
9        ],
10       "positive": [
11         "A02", "B02", "C02", "D02", "E02", "F02", "G02", "H02",
12         "I02", "J02", "K02", "L02", "M02", "N02", "O02", "P02",
13         "A23", "B23", "C23", "D23", "E23", "F23", "G23", "H23",
14         "I23", "J23", "K23", "L23", "M23", "O23", "N23", "P23"
15       ]
16     },
17     "datadir": "data/MAYV/",
18     "fields": 1,
19     "parameters": {"channel": 0, "sigma": 1.0, "min_size": 0, "max_size": 500,
20                   "merge": "sum"},
21     "plates": ["M1", "M2", "M3", "M4", "M5", "M6", "M7", "M8", "M9", "M10",
22               "M11", "M12", "M13", "M14", "M15", "M16", "M17", "M18",
23               "M19", "M20", "M21", "M22", "M23", "M24", "M25"],
24     "selection": {"inCPE": 0.3, "Z": 0.5},
25     "wells": 384
26   }
27 }

```

Figura 6: Exemplo de arquivo de configuração JSON para o protocolo CellViability. O arquivo define os parâmetros necessários para o processamento do ensaio fenotípico de viabilidade celular para o vírus Mayaro.

- **parameters:** parâmetros de pré-processamento, segmentação e mineração, incluindo:
 - **channel:** índice do canal de fluorescência a ser analisado (0 para o canal azul, correspondente ao Hoechst 33342);
 - **sigma:** valor do desvio padrão para o filtro Gaussiano aplicado no pré-processamento;
 - **min_size** e **max_size:** tamanhos mínimo e máximo dos núcleos segmentados, em pixels, para filtragem;
 - **merge:** método de agregação dos campos de imagem por poço (soma).
- **plates:** lista de identificadores das placas a serem analisadas no ensaio;
- **selection:** critérios de seleção dos compostos candidato (*hits*), incluindo:
 - **inCPE:** limiar mínimo de inibição do efeito citopático viral para seleção dos compostos candidatos (padrão: 0,3);

- Z: limiar mínimo do Z' para aprovação das placas no controle de qualidade (padrão: 0,5).

- **wells**: número total de poços por placa (384 para os ensaios deste projeto).

Essa estrutura modular torna o protocolo flexível, permitindo seu uso em diferentes ensaios e facilitando sua integração futura com interfaces gráficas (GUI).

4.2 Leitura dos dados

Os ensaios fenotípicos de viabilidade celular são usualmente constituídos por múltiplas placas de 384 poços, sendo que cada poço pode um ou mais campos (*fields*). Para os ensaios deste projeto (MAYV, OROV, SARS-CoV-2, SLEV), cada poço contém apenas um campo. As imagens foram exportadas pelo software Harmony (PerkinElmer), que adota uma convenção padronizada de nomes de arquivos (e.g, 001001-1-001001001.tif), permitindo identificar metadados essenciais diretamente a partir do nome do arquivo. Esses metadados incluem a identificação do poço (*well*), campo (*field*), canal de fluorescência, plano Z e tempo.

O protocolo desenvolvido requer uma estrutura de diretórios específica para organizar as imagens dos ensaios fenotípicos de viabilidade celular. Na Figura 7, descrevemos o formato esperado para a organização dos dados:

Recentemente, o LNBio adotou o OMERO [15–17] como repositório institucional para armazenamento e gerenciamento de imagens de microscopia ótica. Neste repositório, as imagens são armazenadas com uma nomenclatura de arquivos distinta daquela exportada pelo Harmony (Figura 7). Por esse motivo, para uso de ensaios provenientes do OMERO no presente protocolo, é necessário realizar um pré-processamento de renomeação, de modo a uniformizar os arquivos e torná-los compatíveis com o formato esperado. Como etapa futura, planeja-se implementar a leitura direta das imagens a partir do OMERO, o que eliminará a necessidade de renomeação e permitirá uma integração mais eficiente e transparente com o repositório institucional.




Figura 7: Estrutura de diretórios para os ensaios fenotípicos de viabilidade celular. As imagens devem ser organizadas em diretórios por ensaio (i.e, *screen*), contendo subdiretórios para cada placa (i.e, *plate*), que por sua vez contêm as imagens correspondentes aos campos e canais de fluorescência.

4.3 Segmentação das imagens

5 Resultados preliminares

A partir do software CellProfiler [32] v4.2.6, desenvolvemos um protocolo preliminar baseados em dados da placa *LDV DMSO teste 260324* (26/03/2024) de ensaio fenotípico de viabilidade celular para descoberta de fármacos, fornecidos pelo grupo de Virologia do LNBio/CNPEM. O protocolo foi aplicado a imagens de células Vero CCL81 infectadas com o vírus Mayaro, tratadas com diferentes compostos, além de controles positivo e negativo (Figura 8).

O protocolo preliminar aplica módulos do CellProfiler para as etapas de pré-processamento e segmentação (Figura 9). A primeira etapa consistiu no pré-processamento das imagens, incluindo um filtro de mediana (*MedianFilter*) para suavização do ruído e a operação de abertura (*Opening*) para suavizar os contornos de imagens, remover ruídos e eliminar pequenos espaços entre objetos. Em seguida, a segmentação dos núcleos foi realizada com o módulo *IdentifyPrimaryObjects*, utilizando o método de limiarização de Otsu. As saídas



Figura 8: Exemplos de imagens de células Vero CCL81 da placa *LDV DMSO teste 260324* de ensaio fenotípico de viabilidade celular para descoberta de fármacos. Alta (esquerda), média (centro) e baixa (direita) densidade celular.

do protocolo incluem as marcações dos núcleos segmentados, a contagem de células por poço em formato tabular e visualizações dos resultados, como o mapa da placa e gráficos de dispersão. Para mais detalhes sobre os módulos do CellProfiler, consulte a documentação disponível em <https://cellprofiler-manual.s3.amazonaws.com/CellProfiler-4.2.6/index.html>.




Figura 9: Fluxograma do protocolo preliminar de processamento de imagens em ensaios de viabilidade celular.

Para avaliar o desempenho do protocolo preliminar, comparamos seus resultados com o software comercial Acapella/Columbus. A concordância entre os métodos foi analisada por meio de um gráfico de dispersão (Figura 10).

Os resultados obtidos com o protocolo preliminar indicaram alta correlação ($\rho = 0.998$) entre os dois protocolos, demonstrando a eficácia do protocolo preliminar na identificação e quantificação dos núcleos celulares marcados com Hoechst 33342. Apesar da alta correlação, a análise revelou diferenças de desempenho dependendo da densidade celular. No controle positivo, onde há alta densidade celular, o protocolo preliminar do CellProfiler identificou um maior número de células em comparação ao Acapella/Columbus, indicando uma maior sensibilidade na detecção de núcleos em regiões superpovoadas. Em constrate,




Figura 10: Grafico de dispersão das contagens de núcleos do protocolo preliminar do CellProfiler e do software comercial Acapella/Columbus.

em baixa densidade celular, o Acapella/Columbus identificou um maior número de células, possivelmente devido à classificação de detritos celulares (*debris*) como células viáveis. Para densidades intermediárias, os métodos apresentaram resultados similares, indicando que o protocolo preliminar é competitivo em relação ao software comercial.

As análises das marcações (Figura 11) indicaram que, em alta densidade celular, o Acapella/Columbus desconsiderou células mais escuras, enquanto o CellProfiler as detectou. Em densidade intermediária, ambos os métodos tiveram desempenho equivalente, devido à distribuição dispersa e à morfologia regular das células. Em baixa densidade, a principal diferença foi a detecção de detritos, que o protocolo preliminar do CellProfiler ignorou e o Acapella/Columbus incluiu na contagem. Assim, o protocolo preliminar do CellProfiler apresentou maior especificidade na detecção de núcleos, reduzindo a contagem de detritos e aumentando a precisão na identificação de células viáveis.

Estes resultados sugerem que o protocolo baseado no CellProfiler pode oferecer uma análise mais precisa, potencialmente resultando em um aumento do Z' e melhorando interpretação da eficácia dos compostos testados. Além disso, essa maior precisão pode

reduzir a exclusão de placas por baixa confiabilidade dos dados devido a baixos Z' . No entanto, análises adicionais são necessárias para validar a robustez do protocolo em novos lotes de experimentos.

Um dos desafios observados foi o tempo de processamento maior do protocolo preliminar do CellProfiler em comparação com o Acapella/Columbus. Essa limitação pode ser mitigada ou até solucionada pela migração do protocolo para a linguagem Python, possibilitando a paralelização das tarefas e a otimização do desempenho. Ainda, o uso de Python oferece maior adaptabilidade e flexibilidade, facilitando a integração do protocolo a HPCCs, o que pode aprimorar a escalabilidade e eficiência operacional em análises de larga escala.




Figura 11: Imagens representativas de poços para análise qualitativa. As regiões de interesse determinadas pelo Acapella/Columbus apresentam núcleos contabilizados em verde e núcleos descartados em vermelho, enquanto as regiões de interesse determinadas pelo protocolo preliminar do CellProfiler exibem núcleos contabilizados em vermelho. N_C : contagem de núcleos pelo Columbus. N_{CP} : contagem de núcleos pelo CellProfiler.

6 Considerações finais

Este projeto de pesquisa está vinculado ao projeto interno de Pesquisa e Desenvolvimento "Desenvolvimento de protocolos para análise de bioimagens" da EDB/LNBio/CNPq, com execução prevista para 2025. Com a abertura das instalações do LBE para a comunidade científica, a demanda por protocolos eficientes de análise de bioimagens tem aumentado internamente. Dentre as abordagens atendidas pelo LBE, o processamento de imagens para ensaios fenotípicos de viabilidade celular em experimentos de HCS é uma das mais frequentes. Em parceria com o grupo de Virologia do LNBio/CNPq, este projeto busca desenvolver um protocolo automatizado para processamento de imagens desses ensaios. Além de beneficiar a comunidade científica, o objetivo é capacitar o LBE com uma nova ferramenta de processamento de imagens.

A candidata à bolsa de Iniciação Científica já atua pela EDB, de forma voluntária e sob supervisão, desde agosto de 2024, trabalhando em uma implementação inicial do protocolo. Ela possui conhecimento prévio em programação em Python e experiência em análise de dados biológicos, adquirida tanto em disciplinas da graduação quanto em projetos de pesquisa anteriores. Além disso, destaca a natureza interdisciplinar de seu curso, que envolve uma carga horária semestral extensa, com conteúdos avançados, especialmente em ciências exatas. Apesar dessas exigências, nunca foi reprovada em nenhuma disciplina e tem apresentado evolução acadêmica consistente. Adicionalmente, demonstra excelente desempenho e interesse em ciências da vida. Por fim, a candidata se compromete a continuar aprimorando seus conhecimentos e a manter um desempenho acadêmico adequado nos próximos semestres.

Referências

- 1 LICHTMAN, J. W.; CONCHELLO, J.-A. Fluorescence microscopy. *Nature Methods*, Springer Science and Business Media LLC, v. 2, n. 12, p. 910–919, nov. 2005. ISSN 1548-7105. Disponível em: <<http://dx.doi.org/10.1038/nmeth817>>.
- 2 BALASUBRAMANIAN, H. *et al.* Imagining the future of optical microscopy: everything, everywhere, all at once. *Communications Biology*, Springer Science and Business Media LLC, v. 6, n. 1, out. 2023. ISSN 2399-3642. Disponível em: <<http://dx.doi.org/10.1038/s42003-023-05468-9>>.
- 3 USAJ, M. M. *et al.* High-content screening for quantitative cell biology. *Trends in Cell Biology*, Elsevier BV, v. 26, n. 8, p. 598–611, ago. 2016. ISSN 0962-8924. Disponível em: <<http://dx.doi.org/10.1016/j.tcb.2016.03.008>>.
- 4 WEIGERT, M. *et al.* Content-aware image restoration: pushing the limits of fluorescence microscopy. *Nature Methods*, Springer Science and Business Media LLC, v. 15, n. 12, p. 1090–1097, nov. 2018. ISSN 1548-7105. Disponível em: <<http://dx.doi.org/10.1038/s41592-018-0216-7>>.
- 5 HICKEY, S. M. *et al.* Fluorescence microscopy—an outline of hardware, biological handling, and fluorophore considerations. *Cells*, MDPI AG, v. 11, n. 1, p. 35, dez. 2021. ISSN 2073-4409. Disponível em: <<http://dx.doi.org/10.3390/cells11010035>>.
- 6 FAZEL, M. *et al.* Fluorescence microscopy: a statistics-optics perspective. arXiv, 2023. Disponível em: <<https://arxiv.org/abs/2304.01456>>.
- 7 BRAY, M.-A. *et al.* Cell painting, a high-content image-based assay for morphological profiling using multiplexed fluorescent dyes. *Nature Protocols*, Springer Science and Business Media LLC, v. 11, n. 9, p. 1757–1774, ago. 2016. ISSN 1750-2799. Disponível em: <<http://dx.doi.org/10.1038/nprot.2016.105>>.
- 8 JAN, M. *et al.* From pixels to insights: Machine learning and deep learning for bioimage analysis. *BioEssays*, Wiley, v. 46, n. 2, dez. 2023. ISSN 1521-1878. Disponível em: <<http://dx.doi.org/10.1002/bies.202300114>>.
- 9 WANG, Y. Computational restoration of fluorescence images: Noise reduction, deconvolution, and pattern recognition. In: _____. *Digital Microscopy, 3rd Edition*. Elsevier, 2007. p. 435–445. Disponível em: <[http://dx.doi.org/10.1016/S0091-679X\(06\)81020-4](http://dx.doi.org/10.1016/S0091-679X(06)81020-4)>.
- 10 MALPICA, N. *et al.* Applying watershed algorithms to the segmentation of clustered nuclei. *Cytometry*, Wiley, v. 28, n. 4, p. 289–297, dez. 1998. ISSN 0196-4763. Disponível em: <[http://dx.doi.org/10.1002/\(SICI\)1097-0320\(19970801\)28:4<289::AID-CYTO3>3.0.CO;2-7](http://dx.doi.org/10.1002/(SICI)1097-0320(19970801)28:4<289::AID-CYTO3>3.0.CO;2-7)>.
- 11 LIAO, P.-S.; CHEN, T.-S.; CHUNG, P.-C. A fast algorithm for multilevel thresholding. *J. Inf. Sci. Eng.*, v. 17, p. 713–727, 09 2001.
- 12 SCHMIDT, U. *et al.* Cell detection with star-convex polygons. In: *Medical Image Computing and Computer Assisted Intervention - MICCAI 2018 - 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part II*. [S.l.: s.n.], 2018. p. 265–273.

- 13 STRINGER, C. *et al.* Cellpose: a generalist algorithm for cellular segmentation. *Nature Methods*, Springer Science and Business Media LLC, v. 18, n. 1, p. 100–106, dez. 2020. ISSN 1548-7105. Disponível em: <http://dx.doi.org/10.1038/s41592-020-01018-x>.
- 14 WEIGERT, M.; SCHMIDT, U. Nuclei instance segmentation and classification in histopathology images with stardist. In: *The IEEE International Symposium on Biomedical Imaging Challenges (ISBIC)*. [S.l.: s.n.], 2022.
- 15 ALLAN, C. *et al.* Omero: flexible, model-driven data management for experimental biology. *Nature Methods*, Springer Science and Business Media LLC, v. 9, n. 3, p. 245–253, fev. 2012. ISSN 1548-7105. Disponível em: <http://dx.doi.org/10.1038/nmeth.1896>.
- 16 BUREL, J.-M. *et al.* Publishing and sharing multi-dimensional image data with omero. *Mammalian Genome*, Springer Science and Business Media LLC, v. 26, n. 9–10, p. 441–447, jul. 2015. ISSN 1432-1777. Disponível em: <http://dx.doi.org/10.1007/s00335-015-9587-6>.
- 17 LI, S. *et al.* Metadata management for high content screening in omero. *Methods*, Elsevier BV, v. 96, p. 27–32, mar. 2016. ISSN 1046-2023. Disponível em: <http://dx.doi.org/10.1016/j.jymeth.2015.10.006>.
- 18 KO, S. *et al.* High-performance statistical computing in the computing environments of the 2020s. *Statistical Science*, Institute of Mathematical Statistics, v. 37, n. 4, nov. 2022. ISSN 0883-4237. Disponível em: <http://dx.doi.org/10.1214/21-STS835>.
- 19 BROWN, E. M. *et al.* *BioIO: Image Reading, Metadata Conversion, and Image Writing for Microscopy Images in Pure Python*. GitHub, 2023. Disponível em: <https://github.com/bioio-devs/bioio>.
- 20 WALT, S. van der *et al.* scikit-image: image processing in python. *PeerJ*, PeerJ, v. 2, p. e453, jun. 2014. ISSN 2167-8359. Disponível em: <http://dx.doi.org/10.7717/peerj.453>.
- 21 VIRTANEN, P. *et al.* Scipy 1.0: fundamental algorithms for scientific computing in python. *Nature Methods*, Springer Science and Business Media LLC, v. 17, n. 3, p. 261–272, fev. 2020. ISSN 1548-7105. Disponível em: <http://dx.doi.org/10.1038/s41592-019-0686-2>.
- 22 STRINGER, C.; PACHITARIU, M. Cellpose3: one-click image restoration for improved cellular segmentation. *Nature Methods*, Springer Science and Business Media LLC, v. 22, n. 3, p. 592–599, fev. 2025. ISSN 1548-7105. Disponível em: <http://dx.doi.org/10.1038/s41592-025-02595-5>.
- 23 PACHITARIU, M.; RARIDEN, M.; STRINGER, C. Cellpose-sam: superhuman generalization for cellular segmentation. Cold Spring Harbor Laboratory, maio 2025. Disponível em: <http://dx.doi.org/10.1101/2025.04.28.651001>.
- 24 WEIGERT, M. *et al.* Star-convex polyhedra for 3d object detection and segmentation in microscopy. In: *The IEEE Winter Conference on Applications of Computer Vision (WACV)*. [S.l.: s.n.], 2020.

- 25 ZHANG, J.-H.; OLDENBURG, K. R. Z-factor. In: _____. *Encyclopedia of Cancer*. Springer Berlin Heidelberg. p. 3227–3228. ISBN 9783540476481. Disponível em: <http://dx.doi.org/10.1007/978-3-540-47648-1_6298>.
- 26 ZHANG, J.-H.; CHUNG, T. D.; OLDENBURG, K. R. A simple statistical parameter for use in evaluation and validation of high throughput screening assays. *Journal of biomolecular screening*, Sage Publications Sage CA: Thousand Oaks, CA, v. 4, n. 2, p. 67–73, 1999.
- 27 BRAY, M.-A.; CARPENTER, A.; Imaging Platform, Broad Institute of MIT and Harvard. Advanced assay development guidelines for image-based high content screening and analysis. In: *Assay Guidance Manual*. Bethesda (MD): Eli Lilly & Company and the National Center for Advancing Translational Sciences, 2004.
- 28 HUNTER, J. D. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, IEEE COMPUTER SOC, v. 9, n. 3, p. 90–95, 2007.
- 29 INC., P. T. *Collaborative data science*. Montreal, QC: Plotly Technologies Inc., 2015. Disponível em: <<https://plot.ly>>.
- 30 MCKINNEY, W. Data structures for statistical computing in python. In: *Proceedings of the 9th Python in Science Conference*. SciPy, 2010. (SciPy), p. 56–61. ISSN 2575-9752. Disponível em: <<http://dx.doi.org/10.25080/Majora-92bf1922-00a>>.
- 31 HARRIS, C. R. *et al.* Array programming with numpy. *Nature*, Springer Science and Business Media LLC, v. 585, n. 7825, p. 357–362, set. 2020. ISSN 1476-4687. Disponível em: <<http://dx.doi.org/10.1038/s41586-020-2649-2>>.
- 32 STIRLING, D. R. *et al.* Cellprofiler 4: improvements in speed, utility and usability. *BMC Bioinformatics*, Springer Science and Business Media LLC, v. 22, n. 1, set. 2021. ISSN 1471-2105. Disponível em: <<http://dx.doi.org/10.1186/s12859-021-04344-9>>.